Introducción a la Ciencia de Datos

Equipo Medicina

Adolph, Echeverry y Zerbino

PROBLEMA A RESOLVER

Una de las principales causas de muerte a nivel mundial son las enfermedades cardiovasculares.

Gran parte de los factores de riesgo asociados a la enfermedad son medibles y, muchas veces, prevenibles.

La dificultad está en detectar qué pacientes presentan mayores riesgos de padecerla: no es fácil de hacer desde una sola inspección clínica ni con grandes volúmenes de datos.

Factores de riesgo medibles

- Presión arterial
- Colesterol
- Glucosa
- Adicciones
- Entre otros

PREGUNTA DE INVESTIGACIÓN

¿Es posible identificar patrones en los datos clínicos y de estilo de vida de un paciente que permitan predecir la presencia de una enfermedad cardiovascular?

A partir del dataset de Kaggle analizaremos qué variables están más asociadas a la enfermedad y evaluaremos la posibilidad de construir un modelo que la prediga con la mejor precisión posible.

OBJETIVO GENERAL

Analizar los datos clínicos y el estilo de vida de pacientes para identificar patrones y características asociadas a las enfermedades cardiovasculares y, a partir de esto, desarrollar un modelo que permita predecir si un paciente presenta o no la enfermedad.

1 **Analizar**

Datos clínicos y de estilo de vida de los pacientes.

2 **Identificar**

Patrones y características asociadas a la enfermedad.

3 **Predecir**

Si un paciente presenta o no la patología.

OBJETIVOS ESPECÍFICOS

1. **Limpieza de datos**

   Realizar una correcta limpieza de datos, tanto de valores atípicos o inconsistentes, como también conversión de variables, para obtener un análisis más preciso.

2. **Relación entre variables**

   Analizar la relación entre las variables clínicas y los datos sobre el estilo de vida de los pacientes.

3. **Variables más influyentes**

   Identificar cuáles son las variables con mayor influencia en la presencia de la enfermedad.

OBJETIVOS ESPECÍFICOS

4 **Comparación de perfiles**

Comparar las características de aquellos pacientes que presentan una enfermedad cardiovascular con los que no la tienen.

5 **Modelo predictivo**

Desarrollar un modelo predictivo que permita determinar, con las variables analizadas, si un paciente presenta o no la patología.

6 **Evaluación del modelo**

Evaluar el desempeño del modelo con métricas (precisión, recall, matriz de confusión, entre otras) para determinar qué tan precisa resulta la clasificación.

DATOS A UTILIZAR

“Cardiovascular Disease dataset”, de Svetlana Ulianova, actualizado por última vez hace 8 años. Combina información dada por el paciente, resultados de exámenes médicos y la variable objetivo.

70.000

registros de
distintos pacientes

11

características que
describen a cada uno

1

variable objetivo:
presenta o no la enfermedad

Cada paciente está identificado por un número único.

Las variables, según su tipo de dato

INT **Números enteros**

Edad (en días), altura (en cm), presión arterial sistólica y presión arterial diastólica.

FLOAT **Decimales**

Peso (en kg).

1 / 0 **Binarios**

Fumar, consumo de alcohol, actividad física y la característica objetivo: 1 indica que la condición aplica y 0 que no aplica.

1-2-3 **Códigos categóricos**

Género: 1 (mujer), 2 (hombre). Colesterol y glucosa: 1 (normal), 2 (por encima de lo normal), 3 (muy por encima de lo normal).

Fuente de los datos

Cardiovascular Disease dataset

kaggle.com/datasets/sulianova/cardiovascular-disease-dataset