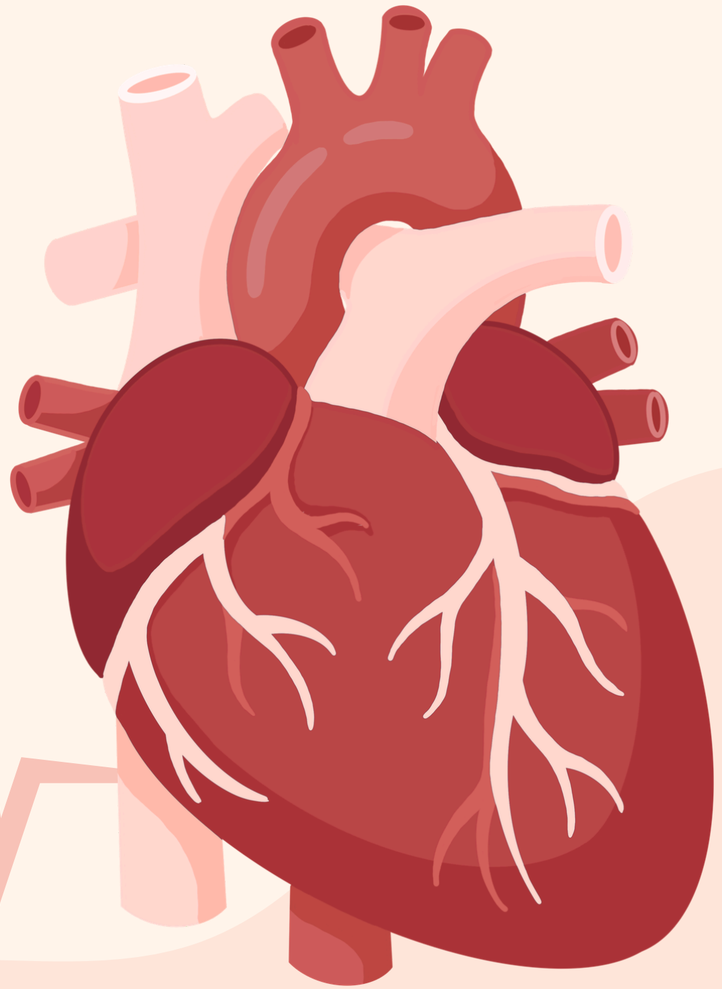
Introducción a la Ciencia de Datos

Equipo Medicina



Adolph, Echeverry y Zerbino

¿Qué son las Enfermedades Cardiovasculares?

Las enfermedades cardiovasculares (ECV) son un grupo de enfermedades que afectan al corazón o a los vasos sanguíneos (venas y arterias).



Algunos factores de riesgo son:

- **Hipertensión arterial**
- **Alimentación no saludable**
- **Colesterol alto**
- **Diabetes**
- **Contaminación atmosférica**

- **Obesidad**
- **Tabaquismo**
- **Inactividad física**
- **Consumo nocivo de alcohol**
- **Estrés**



Inspección inicial de los datos

```python
from pathlib import Path
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
```

```
Descripcion de columnas:                 id           age        gender        height        weight         ap_hi         ap_lo   cholesterol          gluc         smoke          alco            ac
tive       cardio
count   70000.000000  70000.000000  70000.000000  70000.000000  70000.000000  70000.000000  70000.000000  70000.000000  70000.000000  70000.000000  70000.000000  70000.000000  70000.000000
mean    49972.419900  19468.865814      1.349571    164.359229     74.205690    128.817286     96.630414      1.366871      1.226457      0.088129      0.053771      0.803729      0.499700
std     28851.302323   2467.251667      0.476838      8.210126     14.395757    154.011419    188.472530      0.680250      0.572270      0.283484      0.225568      0.397179      0.500003
min         0.000000  10798.000000      1.000000     55.000000     10.000000   -150.000000    -70.000000      1.000000      1.000000      0.000000      0.000000      0.000000      0.000000
25%     25006.750000  17664.000000      1.000000    159.000000     65.000000    120.000000     80.000000      1.000000      1.000000      0.000000      0.000000      1.000000      0.000000
50%     50001.500000  19703.000000      1.000000    165.000000     72.000000    120.000000     80.000000      1.000000      1.000000      0.000000      0.000000      1.000000      0.000000
75%     74889.250000  21327.000000      2.000000    170.000000     82.000000    140.000000     90.000000      2.000000      1.000000      0.000000      0.000000      1.000000      1.000000
max     99999.000000  23713.000000      2.000000    250.000000    200.000000  16020.000000  11000.000000      3.000000      3.000000      1.000000      1.000000      1.000000      1.000000
```

```python
# Detección de altura y peso fuera de rango medico
LIMITE_ALTURA = (120, 220)    # cm
LIMITE_PESO = (30, 200)       # kg

filas_antes = datos_limpios.shape[0]

datos_limpios = datos_limpios[
    datos_limpios["height"].between(*LIMITE_ALTURA) &
    datos_limpios["weight"].between(*LIMITE_PESO)
]
```

Filas antes: 70000 | Filas después: 69940 | Eliminadas: 60

```
Valores únicos en 'id': [    0     1     2 ... 99996 99998 99999]
Cantidad de datos faltantes: id            0
age            0
gender         0
height         0
weight         0
ap_hi          0
ap_lo          0
cholesterol    0
gluc           0
smoke          0
alco           0
active         0
cardio         0
dtype: int64
Cantidad de filas duplicadas: 0
```

Transformación de datos: edad

id	age
0	18393
1	20228
2	18857
3	17623
4	17474
8	21914
9	22113
12	22584
13	17668
14	19834
15	22530
16	18815

```
datos_limpios["age_number"] = (datos_limpios["age"]/365.25).astype(int)
```

```
Valores de edad en años:      age  age_number
0  18393           50
1  20228           55
2  18857           51
3  17623           48
4  17474           47
```

```
Rango de edad en años: 29 - 64
```

Corrección de valores clínicamente imposibles



```
Descripcion de presiones:          ap_hi          ap_lo
count  69940.000000  69940.000000
mean     128.823005     96.630455
std      154.075039    188.514048
min     -150.000000    -70.000000
25%      120.000000     80.000000
50%      120.000000     80.000000
75%      140.000000     90.000000
max    16020.000000  11000.000000
```

==> filas eliminadas aplicando estas correcciones: 1322

- outliers muy alejados de la realidad

```
LIMITE_AP_HI = (60, 250)
LIMITE_AP_LO = (40, 200)

filas_antes = datos_limpios.shape[0]

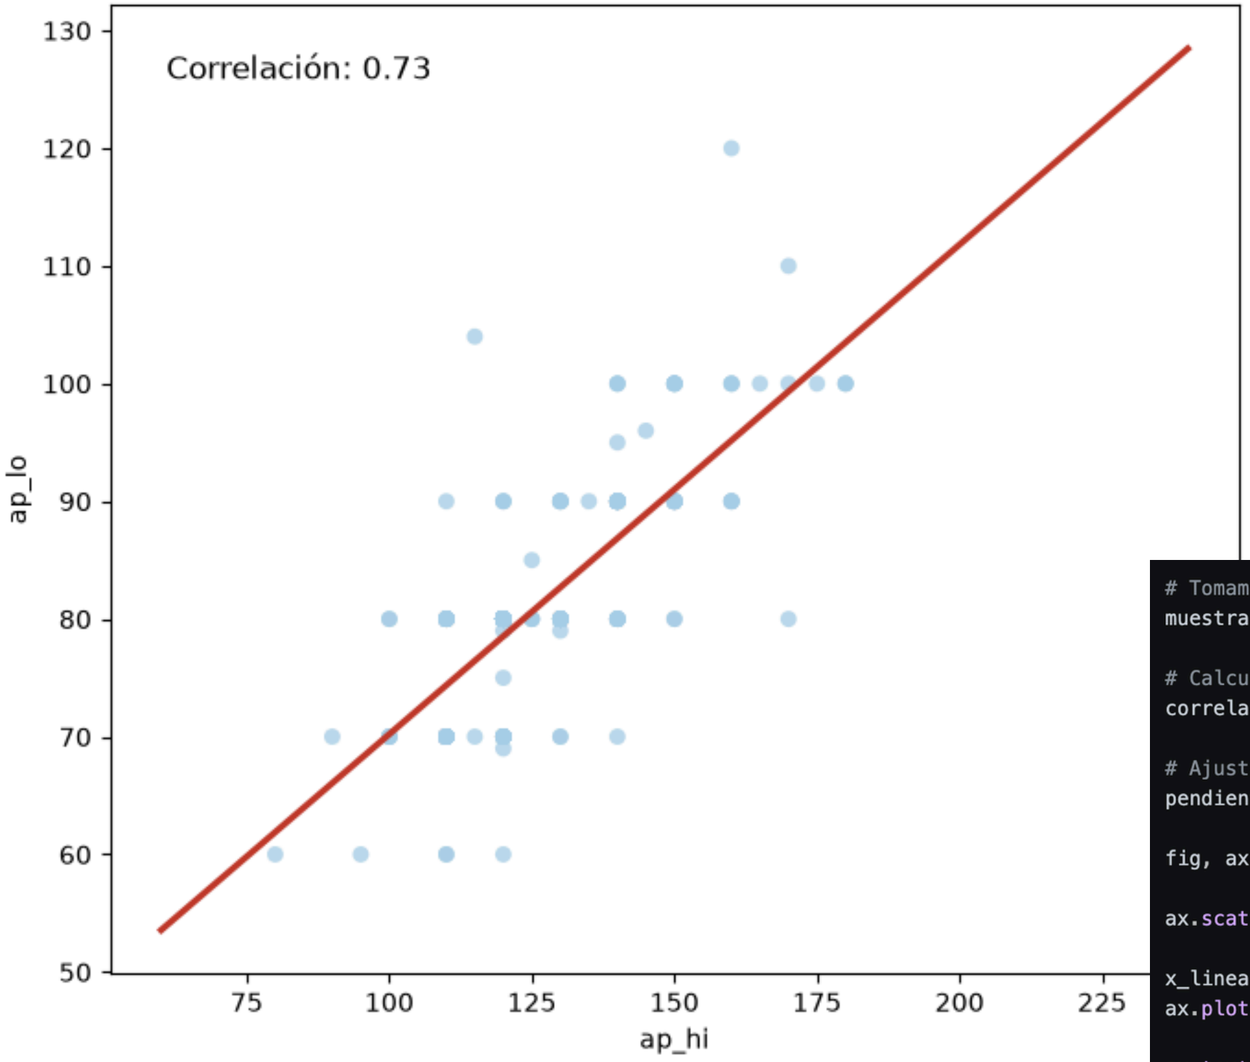
datos_limpios = datos_limpios[
    datos_limpios["ap_hi"].between(*LIMITE_AP_HI) &
    datos_limpios["ap_lo"].between(*LIMITE_AP_LO)
]
```

- datos en los que la presión diastólica supera a la sistólica

```
filas_antes = datos_limpios.shape[0]
datos_limpios = datos_limpios[(datos_limpios["ap_lo"] <= datos_limpios["ap_hi"])]
```

Filas al inicio: 70000
Filas después: 68618
Eliminadas totales: 1382

Exploración de Variables




```python
# Tomamos una muestra para que el gráfico no se sature de puntos
muestra = datos_limpios.sample(n=300, random_state=42)

# Calculamos la correlación sobre TODOS los datos (no solo la muestra), para que sea representativa
correlacion = datos_limpios[x_var].corr(datos_limpios[y_var])

# Ajustamos la recta de regresión lineal (pendiente y ordenada al origen)
pendiente, ordenada = np.polyfit(datos_limpios[x_var], datos_limpios[y_var], 1)

fig, ax = plt.subplots(figsize=(7, 6))

ax.scatter(muestra[x_var], muestra[y_var], color="#A8D0E6", s=40, alpha=0.8, edgecolors="none")

x_linea = np.linspace(datos_limpios[x_var].min(), datos_limpios[x_var].max(), 100)
ax.plot(x_linea, pendiente * x_linea + ordenada, color="#C0392B", linewidth=2.5)

ax.text(0.05, 0.95, f"Correlación: {correlacion:.2f}",
        transform=ax.transAxes, fontsize=12, verticalalignment="top")

ax.set(xlabel=x_var, ylabel=y_var)

# Estilo "caja completa" como en la imagen (a diferencia de los gráficos anteriores, acá SÍ dejamos los 4 bordes)
for lado in ax.spines.values():
    lado.set_visible(True)

plt.tight_layout()
plt.show()
```

Categorizacion de Presion Arterial

Utilizando la imagen, categorizamos la presion segun distintos tipos.

```python
# Categorizar la presión arterial según sistólica (ap_hi) y diastólica (ap_lo) => clasificacion imagen "clasificacion-presion-arterial"
condiciones = [
    (datos_limpios["ap_hi"] > 180) | (datos_limpios["ap_lo"] > 120),                    # Crisis de hipertensión
    (datos_limpios["ap_hi"] >= 140) | (datos_limpios["ap_lo"] >= 90),                    # Hipertensión Nivel 2
    (datos_limpios["ap_hi"].between(130, 139)) | (datos_limpios["ap_lo"].between(80, 89)),    # Hipertensión Nivel 1
    (datos_limpios["ap_hi"].between(120, 129)) & (datos_limpios["ap_lo"] < 80),          # Elevada
    (datos_limpios["ap_hi"].between(80, 120)) & (datos_limpios["ap_lo"].between(60, 80)),    # Normal
    (datos_limpios["ap_hi"] < 80) | (datos_limpios["ap_lo"] < 60),                       # Hipotensión
]

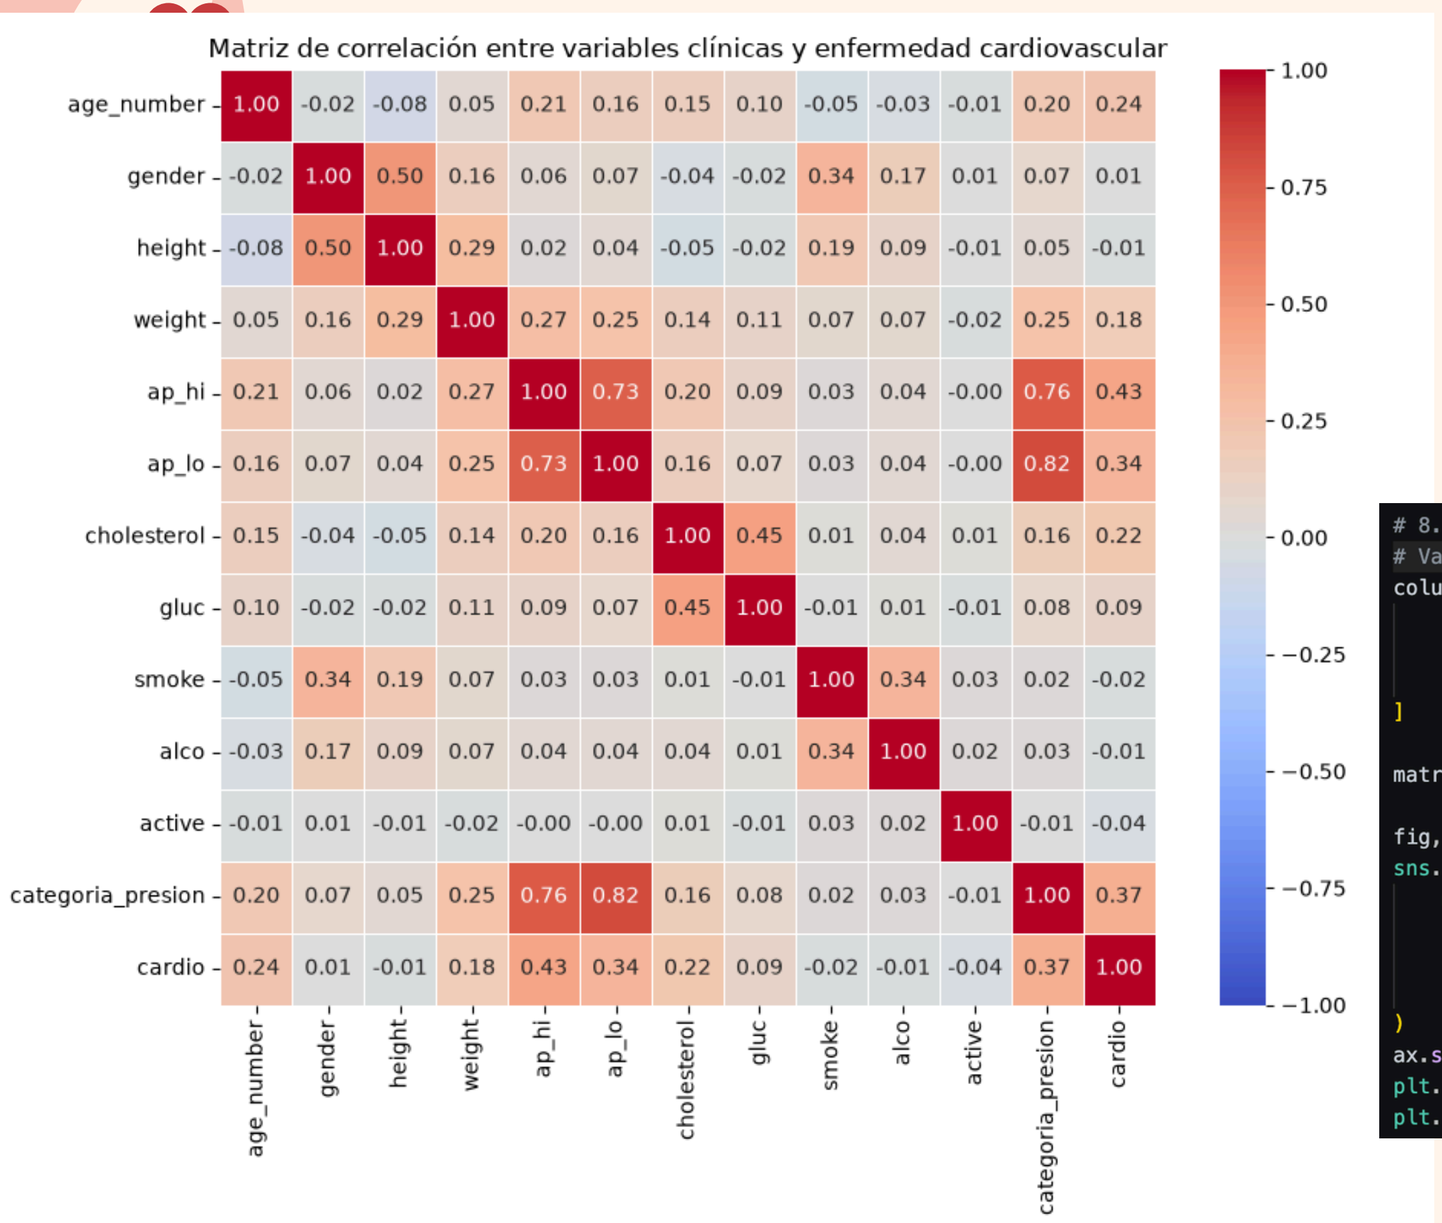
valores = [6, 5, 4, 3, 2, 1]

datos_limpios["categoria_presion"] = np.select(condiciones, valores, default=np.nan)
# np.select toma la PRIMERA condición que se cumpla, por eso el orden de más grave a menos grave

print(datos_limpios["categoria_presion"].value_counts(dropna=False))
print(datos_limpios["cardio"].value_counts(dropna=False))
```

Categoría	Sistólica (mmHg)		Diastólica (mmHg)
Hipotensión	Menor a 80	o	Menor a 60
Normal	80 – 120	y	60 – 80
Elevada	120 –129	y	Menor a 80
Hipertensión Nivel 1	130 –139	o	80 – 89
Hipertensión Nivel 2	≥ 140	o	≥ 90
Crisis de hipertensión	Mayor a 180	y/o	Mayor a 120

Matriz de Correlación

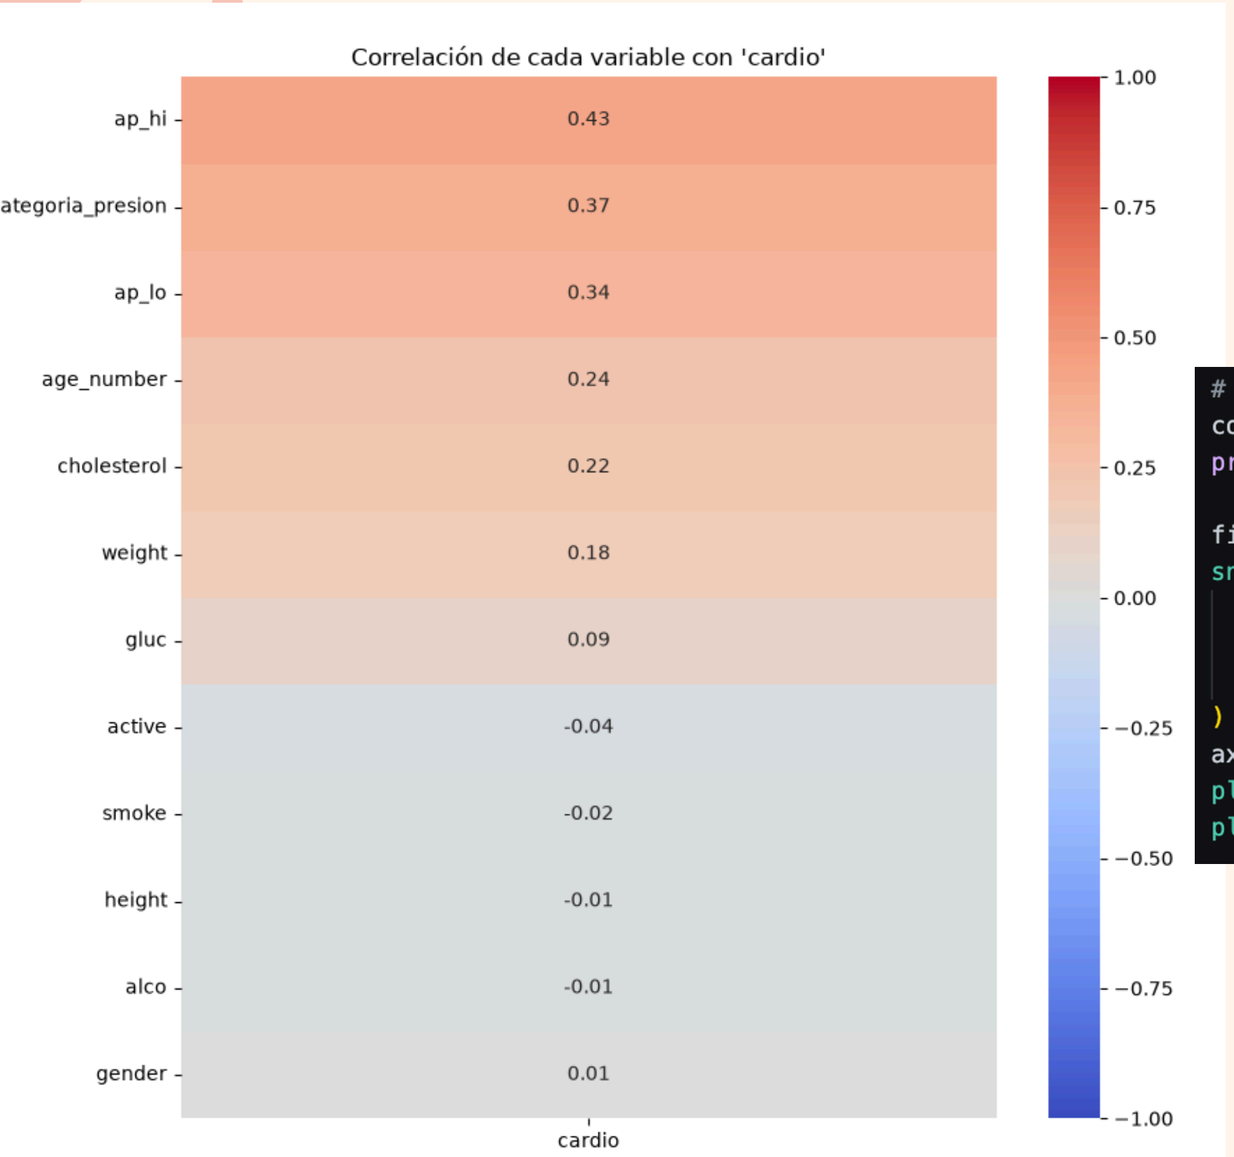



```python
# 8. Generacion de graficos
# Variables numéricas relevantes (usamos age_number en vez de age en días)
columnas_correlacion = [
    "age_number", "gender", "height", "weight",
    "ap_hi", "ap_lo", "cholesterol", "gluc",
    "smoke", "alco", "active", "categoria_presion", "cardio"
]

matriz_corr = datos_limpios[columnas_correlacion].corr()

fig, ax = plt.subplots(figsize=(10, 8))
sns.heatmap(
    matriz_corr,
    annot=True, fmt=".2f",
    cmap="coolwarm", vmin=-1, vmax=1, center=0,
    square=True, linewidths=0.5, ax=ax
)
ax.set_title("Matriz de correlación entre variables clínicas y enfermedad cardiovascular")
plt.tight_layout()
plt.show()
```

Matriz x Cardio




```python
# Heatmap relacionado con cardio
corr_con_cardio = matriz_corr["cardio"].drop("cardio").sort_values(key=abs, ascending=False)
print(corr_con_cardio)

fig, ax = plt.subplots(figsize=(4, 6))
sns.heatmap(
    corr_con_cardio.to_frame(),
    annot=True, fmt=".2f",
    cmap="coolwarm", vmin=-1, vmax=1, center=0, ax=ax
)
ax.set_title("Correlación de cada variable con 'cardio'")
plt.tight_layout()
plt.show()
```

Creación de nuevas Variables

```
# 9. Crear nuevas variables para encontrar correlaciones mas fuertes
datos_limpios["imc"] = datos_limpios["weight"] / (datos_limpios["height"]/100)**2  # Índice de Masa Corporal
datos_limpios["presion_pulso"] = datos_limpios["ap_hi"] - datos_limpios["ap_lo"]
datos_limpios["habitos_riesgo"] = datos_limpios["smoke"] + datos_limpios["alco"] + (1 - datos_limpios["active"])
datos_limpios["sindrome_metabolico"] = (datos_limpios["cholesterol"] + datos_limpios["gluc"])
```

```
# Nos fijamos los valores de las nuevas variables creadas
print(datos_limpios["imc"].value_counts(dropna=False))
print(datos_limpios["habitos_riesgo"].value_counts(dropna=False))
print(datos_limpios["sindrome_metabolico"].value_counts(dropna=False))
print(datos_limpios["presion_pulso"].value_counts(dropna=False))
```

Categorización del IMC

```
# Categorizar el IMC según la OMS => clasificacion imagen "indice_masa_corporal"
condiciones_imc = [
    datos_limpios["imc"] < 18.5,                                          # Bajo peso
    (datos_limpios["imc"] >= 18.5) & (datos_limpios["imc"] < 25),  # Normal
    (datos_limpios["imc"] >= 25)   & (datos_limpios["imc"] < 30),  # Sobrepeso
    (datos_limpios["imc"] >= 30)   & (datos_limpios["imc"] < 35),  # Obesidad I
    (datos_limpios["imc"] >= 35)   & (datos_limpios["imc"] < 40),  # Obesidad II
    datos_limpios["imc"] >= 40,                                           # Obesidad III
]

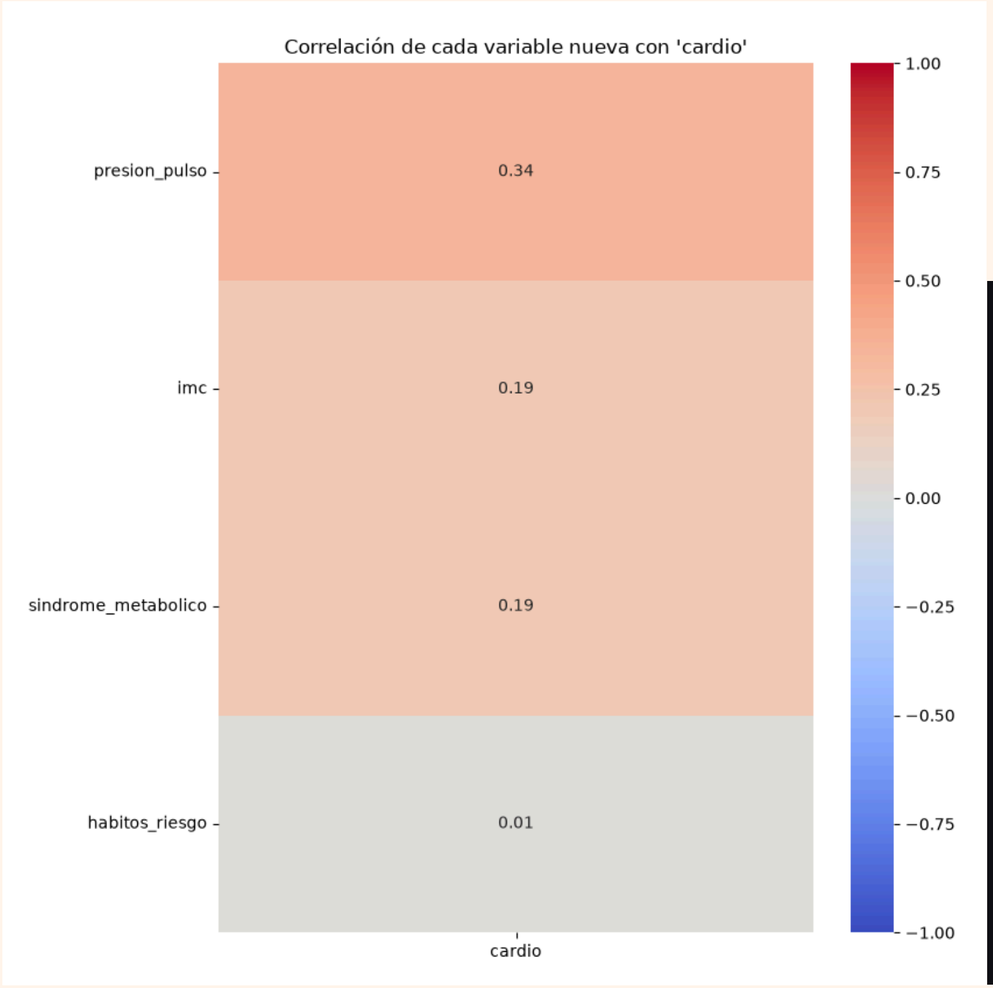
valores_imc = [1, 2, 3, 4, 5, 6]
```

categoria_imc	
1.0	636
2.0	25425
3.0	24624
4.0	11940
5.0	4229
6.0	1764




```
datos_limpios["categoria_imc"] = np.select(condiciones_imc, valores_imc, default=np.nan)
print(datos_limpios["categoria_imc"].value_counts(dropna=False).sort_index())
```

Correlación nuevas variables



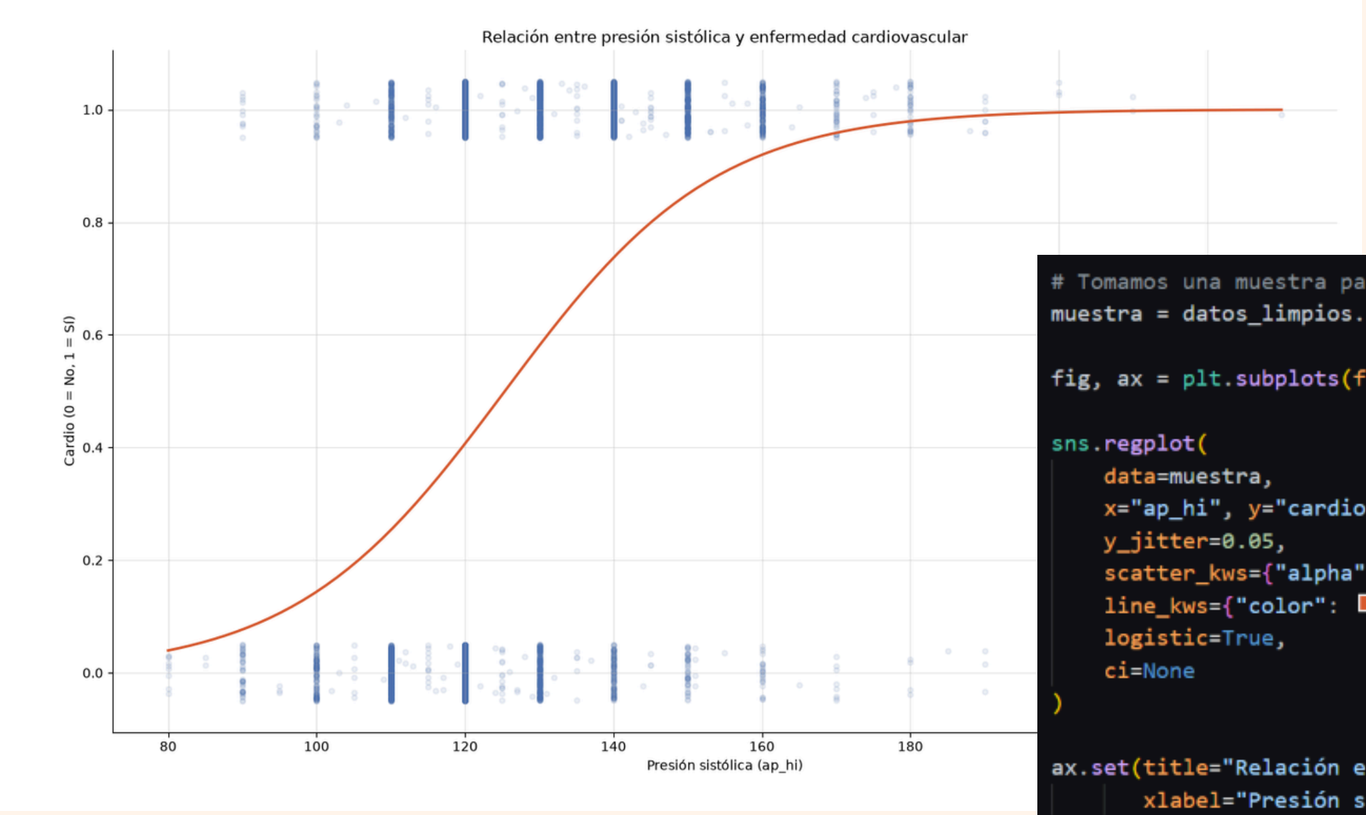

```python
# Heatmap de correlación con nuevas variables
columnas_correlacion_nueva = [
    "imc", "presion_pulso", "habitos_riesgo", "sindrome_metabolico", "cardio"
]

matriz_corr2 = datos_limpios[columnas_correlacion_nueva].corr()

corr_con_cardio = matriz_corr2["cardio"].drop("cardio").sort_values(key=abs, ascending=False)
print(corr_con_cardio)

fig, ax = plt.subplots(figsize=(4, 6))
sns.heatmap(
    corr_con_cardio.to_frame(),
    annot=True, fmt=".2f",
    cmap="coolwarm", vmin=-1, vmax=1, center=0, ax=ax
)
ax.set_title("Correlación de cada variable nueva con 'cardio'")
plt.tight_layout()
plt.show()
```

Correlación ap_hi y cardio




```python
# Tomamos una muestra para que el gráfico sea rápido (el resultado visual es prácticamente igual)
muestra = datos_limpios.sample(n=5000, random_state=42)

fig, ax = plt.subplots(figsize=(8, 6))

sns.regplot(
    data=muestra,
    x="ap_hi", y="cardio",
    y_jitter=0.05,
    scatter_kws={"alpha": 0.1, "s": 15, "color": "#4C72B0"},
    line_kws={"color": "#D85A30", "linewidth": 2},
    logistic=True,
    ci=None
)

ax.set(title="Relación entre presión sistólica y enfermedad cardiovascular",
       xlabel="Presión sistólica (ap_hi)", ylabel="Cardio (0 = No, 1 = Sí)")
ax.grid(alpha=0.3)

for lado in ("top", "right"):
    ax.spines[lado].set_visible(False)

plt.tight_layout()
plt.show()
```

Muchas gracias

